



Documentação da Inteligência Preditiva

Sistema AgroRisk · Modelo Preditivo de Risco Operacional

Challenge Sompo Seguros

Integrantes do Grupo

Arthur Prudêncio Soares (RM569295)

Caroline Coelho Mendes (RM570370)

Leandro Paiva (RM572159)

Lucas Viana de Lima (RM571835)

Matheus Tavares Lima (RM572808)

■ Visão Geral

No agronegócio, maquinários pesados (tratores, colheitadeiras e pulverizadores) operam em terrenos hostis. Chuvas recentes e solos instáveis causam atolamentos e tombamentos, gerando altos custos de manutenção, tempo de máquina parada e sinistros caros para a seguradora.

Para antecipar esses eventos, o sistema AgroRisk utiliza um modelo de Inteligência Artificial que transforma variáveis de campo (sensores IoT e dados climáticos) em um Score de Risco de 0 a 100. Este documento explica, de forma clara, como esse modelo funciona: quais dados ele usa, como o algoritmo Random Forest foi aplicado, como o score é calculado, como o risco é classificado e por que esse algoritmo foi escolhido.

■ 1. Variáveis de Entrada do Modelo

O modelo utiliza 5 variáveis preditivas (features) para estimar a probabilidade de um acidente operacional. Cada variável representa uma condição mensurável do ambiente ou do equipamento:

Variável	Unidade	Origem	O que representa
Chuva acumulada	mm	API de Clima	Chuva das últimas 48h. Indica saturação do terreno.
Umidade do solo	% (0–100)	Sensor ESP32	Solo encharcado reduz a tração e a aderência.
Inclinação	graus (0–35)	Sensor ESP32	Quanto maior, maior o risco de tombamento.
Peso da máquina	ton (10–25)	Sistema (fixo)	Máquinas pesadas afundam mais em solo mole.
Distância da água	m (0–1000)	GPS / Mapa	Proximidade de rios eleva risco de atolamento.

A variável-alvo (aquilo que o modelo aprende a prever) é `ocorreu_acidente`, um valor binário: 0 = sem acidente, 1 = acidente. Ela é utilizada apenas durante o treinamento.

Base de dados utilizada

O modelo foi treinado com um dataset simulado de 1.500 registros, gerado com semente fixa para garantir reprodutibilidade. Cada registro combina as 5 variáveis acima com o resultado (houve ou não acidente), permitindo o aprendizado supervisionado.

■ 2. Como o Random Forest foi Utilizado

O algoritmo escolhido foi o Random Forest Classifier, um modelo que combina várias árvores de decisão. Cada árvore "vota" em um resultado, e a decisão final é o consenso do conjunto. Isso torna o modelo mais estável e preciso do que uma única árvore.

2.1 Configuração do modelo

```
modelo = RandomForestClassifier(n_estimators=100, random_state=42)
modelo.fit(X_train, y_train)
```

main.py (linhas 106–107)

› **n_estimators = 100**

A floresta é formada por 100 árvores de decisão. Mais árvores reduzem erros e o risco de o modelo "decorar" os dados (overfitting).

› **random_state = 42**

Garante que o treinamento seja sempre igual quando repetido (resultado reproduzível).

2.2 Divisão dos dados (treino e teste)

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)
```

main.py (linha 104)

80% dos dados são usados para treinar o modelo e 20% ficam reservados para testá-lo. Assim, avaliamos o desempenho em dados que o modelo nunca viu, medindo sua real capacidade de generalização.

2.3 Validação e explicabilidade

Após o treino, o modelo é avaliado pela acurácia, pelo relatório de classificação (precisão, recall e F1) e pela matriz de confusão. Além disso, o Random Forest informa a importância de cada variável, mostrando quais fatores mais pesam na previsão, o que traz transparência às decisões da IA.

■ 3. Como o Score de Risco é Calculado

O Score de Risco não é uma resposta "sim ou não". Ele é a probabilidade de acidente estimada pelo modelo, convertida para uma escala fácil de ler, de 0 a 100.

```
todas_probabilidades = modelo.predict_proba(X)
df['score_risco'] = np.round(todas_probabilidades[:, 1] * 100, 2)
```

main.py (linhas 152–153)

Passo a passo do cálculo:

- › **1.** `predict_proba` retorna a probabilidade de cada classe: [sem acidente, com acidente].
- › **2.** Selecionamos a probabilidade da classe "com acidente".
- › **3.** Multiplicamos por 100 para transformar em percentual (0 a 100).
- › **4.** Arredondamos para 2 casas decimais.

Exemplo prático

Um score de 82,55 significa que o modelo estima 82,55% de probabilidade de acidente naquelas condições. Como essa probabilidade vem da votação das 100 árvores, ela representa o grau de consenso da floresta sobre o perigo da operação.

4. Classificação dos Níveis de Risco

Para facilitar a decisão no campo, o score numérico é traduzido em 4 níveis qualitativos, cada um associado a uma ação operacional clara:

Nível	Faixa de Score	Ação Operacional Recomendada
● BAIXO	0 – 25	Operação segura. Condições dentro dos parâmetros ideais.
● MÉDIO	26 – 50	Prosseguir com atenção redobrada aos sensores de inclinação.
● ALTO	51 – 75	Reduzir velocidade e evitar rotas declivosas ou próximas à água.
● CRÍTICO	76 – 100	Paralisar as operações imediatamente (risco iminente).

Esses níveis alimentam diretamente o dashboard do projeto: o operador recebe alertas visuais distintos (verde, amarelo, laranja e vermelho) e o gestor acompanha o indicador de "Alertas Críticos" para priorizar intervenções.

5. Justificativa da Escolha do Algoritmo

O Random Forest foi escolhido por equilibrar precisão, transparência e simplicidade operacional, o perfil ideal para um sistema preventivo de campo. Os principais motivos são:

› Captura de relações complexas

O risco agrícola não é linear: a combinação de alta inclinação, solo encharcado e máquina pesada é muito mais perigosa que cada fator isolado. Árvores de decisão modelam naturalmente essas interações.

› Explicabilidade

Diferente de modelos "caixa-preta", o Random Forest mostra a importância de cada variável. Isso permite à seguradora auditar e justificar as decisões da IA.

› Robustez a ruído

Ao combinar 100 árvores, o modelo reduz erros e lida bem com os dados ruidosos típicos de sensores IoT em campo.

› Saída probabilística

Fornece um score contínuo (0 a 100) em vez de apenas sim ou não, viabilizando os 4 níveis de risco graduais e alertas proporcionais.

› Operação local e leve

Roda localmente, com baixa latência, sem necessidade de GPU ou nuvem, e não exige normalização das variáveis (lida bem com escalas diferentes).

Em resumo

O Random Forest entrega precisão, explicabilidade e simplicidade operacional ao mesmo tempo, exatamente o que um sistema de prevenção precisa para ser confiável no campo, auditável pela seguradora e executável em hardware modesto.